

BÙI TRUNG TÍN

Kỹ sư AI · Hệ thống LLM · Phần mềm nghiên cứu

TP. Hồ Chí Minh, Việt Nam · (+84) 384 446 335 · work.trungtin@gmail.com · github.com/MidoriyaHero · LinkedIn

HỌC VẤN

Trường Đại học Quốc tế, Đại học Quốc gia TP. Hồ Chí Minh

Kỹ sư Kỹ thuật Y sinh

TP. Hồ Chí Minh

2020 - 01/2025

- GPA: 3,54/4,00; điểm khóa luận: 94/100; TOEIC: 870.
- Giải Student Best Poster Presentation, Hội nghị Quốc tế lần thứ 10 về Phát triển Kỹ thuật Y sinh tại Việt Nam, 2024.

KINH NGHIỆM

LOGINEX Technology

Kỹ sư AI

Từ xa

2026 - Hiện tại

- Xây pipeline OCR biến số xe, chuyển hình ảnh phương tiện thành dữ liệu biến số có cấu trúc cho workflow vận hành.
- Phát triển hệ thống RAG doanh nghiệp với kiểm soát truy cập theo vai trò và thuộc tính (RBAC/ABAC), bảo đảm kết quả truy xuất tuân theo vai trò, thuộc tính tài nguyên và ngữ cảnh nghiệp vụ.

viAct

Kỹ sư Gen AI

Việt Nam

03/2025 - 07/2026

- Xây dựng dịch vụ production bằng FastAPI, Celery và React cho vận hành công trường, kết nối luồng CCTV, tài liệu và công cụ quy trình qua API có xác thực và môi trường Docker.
- Phát triển hệ sinh thái Slack và Jira agent có tool action, bộ nhớ dài hạn và bước duyệt human-in-the-loop, giảm khoảng 70% thời gian tạo và theo dõi công việc.
- Thiết kế hệ thống truy xuất CCTV end-to-end: ingest và chia video, tạo embedding, lập chỉ mục trong ChromaDB, rồi ánh xạ truy vấn ngôn ngữ tự nhiên thành đoạn thời gian có bộ lọc camera và khoảng ngày.
- Triển khai RAG doanh nghiệp và pipeline document intelligence bằng Elasticsearch và PostgreSQL; tích hợp OCR chữ viết tay tùy chỉnh, đạt khoảng 90% độ chính xác trên biểu mẫu công trường phức tạp.
- Tích hợp WhisperX cho phiên âm và căn chỉnh âm thanh, giảm khoảng 40% lỗi phiên âm trong workflow xử lý media vận hành.
- Xây workflow SAM toàn vòng đời gồm giao diện gán nhãn, đồng bộ Google Drive, tự động chuyển dữ liệu SAM sang YOLO và script serving model cho bài toán an toàn công trường.
- Vận hành workload thị giác máy tính RTSP trực tiếp trên Ray Serve và triển khai cơ chế tự động gỡ model không hoạt động để giải phóng tài nguyên GPU.
- Lượng tử hóa Qwen-VL, chuyển YOLO và OCR sang ONNX, tích hợp vLLM; giảm khoảng 60% bộ nhớ GPU và tăng thông lượng suy luận khoảng 3 lần.

GrantForward · Cazoodle

Kỹ sư Phần mềm Nghiên cứu

Từ xa

09/2025 - 10/2025

- Kiến trúc prototype khám phá tài liệu học thuật, lập chỉ mục kho văn bản lớn và kết hợp truy hồi vector ngữ nghĩa với RAG cho câu hỏi khoa học phức tạp.
- So sánh kết quả ngữ nghĩa với baseline từ khóa và ghi lại các trade-off về chất lượng truy hồi cùng khả năng bảo trì cho đội sản phẩm phân tán.

FPT Digital

Thực tập sinh Kỹ sư AI, toàn thời gian

TP. Hồ Chí Minh

01/2025 - 03/2025

- Chuyển yêu cầu stakeholder thành trợ lý RAG nội bộ giúp nhân viên truy xuất tri thức và lập lại chất lượng câu trả lời theo phản hồi vận hành.
- Nghiên cứu và prototype workflow AI doanh nghiệp, phối hợp cùng đội kỹ thuật và các bên nghiệp vụ.

Công ty Cổ phần IVS

Thực tập sinh Kỹ sư AI, hybrid

TP. Hồ Chí Minh

07/2023 - 08/2024

- Thu thập, làm sạch và tiền xử lý tập văn bản y khoa tiếng Việt quy mô lớn phục vụ huấn luyện và đánh giá mô hình.
- Fine-tune Vistral, PhoGPT, Llama 2 và SeaLLM bằng LoRA/QLoRA để phát triển trợ lý y khoa chuyên biệt.
- Huấn luyện và đánh giá mô hình BERT đạt 83% accuracy trên 23 lớp y khoa.

- Áp dụng U-Net, ResNet-50, VGG-16/19, CNN và YOLOv5 cho phân đoạn và phân loại ảnh y khoa, đạt 97% accuracy trong phân loại bệnh da.
- Tiền xử lý và phân tích ảnh MRI não cho bài toán phân loại bệnh Alzheimer bằng CNN.
- Xây hệ thống RAG bằng LangChain và Elasticsearch để truy xuất thông tin sức khỏe tinh thần.

Trợ giảng, AI for Healthcare

08/2023 - 08/2024

- Hướng dẫn hơn 50 sinh viên Kỹ thuật Y sinh; chuẩn bị bài thực hành lập trình, tài liệu kỹ thuật, bài kiểm tra và bài tập về machine learning ứng dụng.

DỰ ÁN TIÊU BIỂU

Tối ưu Fine-tuning LLM Y khoa — Tối ưu LLaMa2-7B cho hỏi đáp y khoa bằng QLoRA; đạt BERTScore F1 0,841 so với Gemini 0,849 và GPT 0,855, đồng thời giữ kích thước nhỏ và thời gian fine-tune nhanh hơn.

ERP Vận hành Cửa hàng Gas — Phát triển FastAPI/PostgreSQL API, web React và Expo Android offline-first với JWT hai chế độ, backend RBAC, SQLite outbox sync idempotent, công nợ theo đơn, kho, kiểm kê vò, Docker Compose và CI.

Nền tảng Mental Health RAG — Xây trải nghiệm truy xuất full-stack với React, LangChain, FastAPI và Elasticsearch, trả lời câu hỏi sức khỏe tinh thần từ kho tri thức đã lập chỉ mục.

Đồ án Kỹ thuật Y sinh HI-CARD — Phát triển sản phẩm chăm sóc sức khỏe với backend Python và giao diện thông tin đồng hành.

Bộ ngữ liệu y khoa tiếng Việt VHCOR — Đồng phát triển dataset nhận diện chuyên khoa y tế tiếng Việt, công bố phương pháp và benchmark tại hội nghị quốc tế.

CÔNG BỐ KHOA HỌC

- “Optimizing LLaMa2 Fine-Tuning with LoRA and Quantization for Medical Question Answering,” BME 2024, IFMBE Proceedings, Springer, xuất bản online 2025.
- “VHCOR: Vietnamese HealthCare Corpus - A Comprehensive Dataset for Vietnamese Clinic Recognition,” International Conference on Health Science and Technology, 2023.

KỸ NĂNG CHUYÊN MÔN

AI ứng dụng: Kiến trúc RAG, AI agent, LLM fine-tuning, LoRA/QLoRA, đánh giá truy hồi, prompt engineering, OCR, WhisperX, document intelligence.

Thị giác máy tính: YOLO, SAM, Qwen-VL, OpenCV, U-Net, ResNet, pipeline video RTSP.

Phần mềm và dữ liệu: Python, FastAPI, Django, React, TypeScript, PostgreSQL, MongoDB, Elasticsearch, ChromaDB, Celery, REST API.

Hạ tầng: PyTorch, Hugging Face, Ray Serve, vLLM, ONNX, Docker, Git.

CHỨNG CHỈ VÀ GIẢI THƯỞNG

Chứng chỉ: Claude Code in Action; AWS Cloud Technical Essentials; Neural Networks and Deep Learning; TOEIC Speaking and Writing 310.

Giải thưởng: Student Best Poster Presentation, BME10 (2024); The Most Favorite Idea Award.